

최지환

📍 서울 ✉️ jhwan333@gmail.com ☎️ 010-9692-6526 in jihwan-choi 🌐 jhwanchoi jhwanchoi.github.io

프로필

프로덕션 **Generative AI**와 자율주행 AI를 위한 MLOps 추론·평가 플랫폼을 만들고 운영하는 소프트웨어 엔지니어입니다. **Vertex AI** 기반 **Gemini** 멀티모달 추론(실고객 릴리즈 운영), LLM 비용·사용량 관측, RAG, agentic 툴링을 직접 구축하고, 그 기반인 공유 Kubernetes GPU 클러스터를 공동 설계(스케줄러·큐 정책 주도)했으며 추론·평가 워크플로우 **SVEvalFlow**(Inferit, MTBF Validation, PRISM)를 단독 오너십으로 책임집니다. 기술을 측정 가능한 비즈니스 가치로 연결합니다: 20,000시간 검증을 6개월+ → 1.5개월로 단축(430,851 clips, 99.87%), 비용 분석 기반 On-Premise 전환으로 AWS 대비 **4.48억원(55%)** 절감, 일일 8,000만 건 로그 분석 플랫폼으로 월 약 1억원 과다 정산 방지.

경력

Stradvision, 소프트웨어 엔지니어

서울, 대한민국
2022년 7월 - 현재

MLOps 플랫폼 [Link]

공유 GPU 클러스터 공동 설계 & SVEvalFlow(추론·평가) 오너 (2025년 10월 - 현재)

기술: RKE2, Ray, KubeRay, KServe, Knative, MLflow, Airflow, ArgoCD, Harbor, lakeFS, GitHub Actions, Helm

- RKE2 Kubernetes 기반 공유 GPU 클러스터(60+ 이중 GPU: RTX 3090/4080/4090/5090, RTX 6000)를 타 엔지니어와 공동 설계·구축하며 스케줄러·큐 정책 설계를 주도하고, 15+ MLOps 컴포넌트(Ray/KubeRay, MLflow, Airflow, ArgoCD, KServe, Harbor)를 통합
- 학습 워크플로우(SVDeepFlow)는 협업, 추론·평가 워크플로우(**SVEvalFlow**)를 단독으로 책임지고 설계·구축·운영 — 아래 Inferit, MTBF, PRISM으로 구성
- GitHub Actions + ArgoCD CI/CD 파이프라인 3종, KServe/Knative 기반 Scale-to-Zero 서버리스 추론으로 GPU 유휴 비용 절감
- AI-native 개발 도구(Claude Code, Gemini CLI, Codex; MCP/Plugin/Skill)의 사내 도입을 주도 — 실무 엔지니어링 세션 진행 및 n8n 업무 자동화 프로토타입 구축

Inferit [Link]

svnet3 빌드·추론 가속 & 형상관리

기술: FastAPI, Airflow, Kubernetes, lakeFS, Docker, PostgreSQL, HCP Object Storage

- svnet3(사내 자율주행 비전 모델)를 다양한 config로 빌드하는 버전·형상·아티팩트 관리 체계 구축
- 단일 머신 추론을 클러스터 GPU 분산·병렬로 가속 — 20,000시간 데이터 검증에 예상 6개월+에서 1.5개월로 단축
- 고객사 option 파일(카메라 파라미터 등)을 형상관리해 티켓마다 1-2일 걸리던 엔지니어-PM 간 탐색·핸드오프 제거
- 메이저 릴리즈 5+ 버전을 호환하고, 고객 이슈 티켓 기반 자동 추론(OD/LD/TSR/TLR feature 단위, 주수회)과 Evaluation-Driven Development(평가 자동화)를 통합

MTBF Validation [Link]

svnet3 대규모 신뢰성 검증

기술: FastAPI, Airflow, Kubernetes, Docker, PostgreSQL, HCP Object Storage

- 릴리즈 전·후 고객 ODD 주행 데이터에 svnet3 추론을 돌려 false positive와 AEB flag를 표시하고 평가를 자동화. **430,851 clips**를 **99.87%** 성공률로 처리(누적 15,233h)했고, 단일 머신 대비 처리량 205% 증가·처리 시간 67.3% 감소 — 15,233h 중 실제 false positive ~10건(~5,000h당 1건)
- 비용 분석 기반 Cloud to On-Premise 전환 제안·실행: AWS 8.2억 → On-Premise 3.7억(55% 절감). GPU 하드웨어 벤치마크·사양 제안, HCP Object Storage 활용
- 자동화로 소규모만 가능하던 대규모 검증을 1인 운영으로 전환. 7종 검증 파이프라인·모니터링 대시보드·Visual Inspection UI + **Vertex AI** 기반 **Gemini 2.5 Flash** 자동 FP 검출 보조(멀티모달·structured output, 최종 판단은 사람)

PRISM [Link]

고객 Jira 연동 ISP 변환·Re-simulation 파이프라인 (2025년 11월 -)

기술: FastAPI, Airflow, PostgreSQL, AWS (SQS, Lambda), Terraform

- **Phase 1 (전개 준비):** Jira Webhook to SQS to Lambda 이벤트 기반 ISP 변환 자동화, 사내 ISP 변환툴 연동. 연동 테스트 완료, Inferit 전개 후 완전 전개 예정. 월 ~150건 처리 · 수동 대비 약 80% 단축을 목표로 설계
- **Phase 2 (Resim, 개발 중):** 초기 버전을 개발한 뒤 테크니컬 리드로 타 조직 개발자의 구현을 지원. SWIT Docker Image 기반 이슈/최신 버전 동시 추론, Airflow DAG 트리거

데이터 · 라벨링 자동화 (2022 - 2025)

- **WLS:** 일일 8,000만 건 라벨링 로그 수집 · 분석으로 월 약 1억원 과다 정산 방지(정산 감사 확정치). 로그 분석으로 작업 병목을 규명해 UI/UX 개선 및 ALAS 자동 라벨링 모델로 연결하고, 라벨링 효율을 20% 향상 (Django, MongoDB, AWS SQS)
- **ALAS:** 객체 자동 라벨링 마이크로서비스로 수동 라벨링 워크로드 약 35% 감소. ECS to EKS 마이그레이션, CDK 기반 IaC (FastAPI, AWS SQS, AWS SNS, AWS ECS/EKS, CDK)
- **IGS:** 외부 고객사 데이터 Ingestion 서비스 기획 및 아키텍처 설계(REST API/DB 스키마, Airflow 변환 파이프라인 설계) (Django, Airflow, Kubernetes)
- **SURF Compass:** 데이터 수집 장비 모니터링 서비스 기획 및 설계 (FastAPI, PostgreSQL)
- **RNS:** NestJS + Atlassian API로 Jira 기반 릴리즈 노트 자동 생성, 작성 시간 50% 단축(4시간 에서 2시간) (NestJS, Atlassian API)
- **SLT:** C++/MFC 기반 2D LD 라벨링 툴 개발, 생산성 30% 향상 (C++/MFC)

한국로봇융합연구원, 연구원

포항, 대한민국

- 제스처 인식 기반 실시간 Human-Robot Interaction 시스템 개발
- 자폐 진단 보조 로봇 프로젝트 지원

2022년 1월 - 2022년 7월

기술 스택

언어: Python, C++, TypeScript

Backend: Django, FastAPI, NestJS

Database: PostgreSQL, MongoDB, Redis

Cloud: GCP (Vertex AI), AWS (EC2, EKS, ECS, SQS, SNS, Lambda, S3, Bedrock)

Infrastructure: Kubernetes (RKE2), Docker, Terraform, CDK, Rancher

ML/MLOps: Ray, KubeRay, MLflow, KServe, Knative, lakeFS

Workflow: Airflow, Celery

CI/CD: ArgoCD, GitHub Actions, Harbor, Helm

Monitoring: Grafana, Prometheus, Loki, DataDog

Generative AI / LLM: Vertex AI (Gemini), AWS Bedrock, 멀티모달, structured output, RAG / embeddings, 프롬프트 엔지니어링, LLM 비용 · 관측, agentic / tool-use, 멀티모델 오케스트레이션, Claude Code / MCP / Skills

Tools: Git, Jira, Confluence, Atlassian API

Generative AI Engineering

- **Gemini · Vertex AI (프로덕션 · 멀티모달):** 자율주행 비전 모델 추론 결과 자동 FP 검출용 Vertex AI 기반 Gemini 2.5 Flash 서비스(이미지 + 구조화 메타데이터). JSON 스키마 기반 structured output, request당 토큰 추적, 배치 비동기 + 중복제거(~40% 호출 감소)를 적용하고 휴먼인더루프를 유지. 실고객 릴리즈 평가 운영(MTBF)
- **LLM 비용 · 사용량 관측 (AWS Bedrock):** 토큰 단위 및 모델 · 팀별 request당 비용 귀속을 CloudWatch + Slack으로 노출하고 Terraform IaC로 구현. 청구 대비 90%+ 정확도, 조직 차원 비용 최적화 의사결정 도구로 활용
- **RAG 지식 시스템 (LLM Wiki):** 키워드 + 임베딩 하이브리드 검색(text-embedding-3-small, 벡터 인덱스, 코사인 top-k) → 출처 · 최신성 · 불확실성 표시를 갖춘 근거 답변. CI 임베딩 인덱스 재생성 (Git + Markdown)
- **Agentic LLM 툴링:** 자연어 의도 → 클러스터 진단/스토리지 도구 호출(ClaudeCode Skills), 멀티스텝 오케스트레이션 + 가드레일(dry-run, 롤백, 확인 게이트) 적용. 멀티모델 자기비판 워크플로우(Claude/GPT/Gemini) 운영 (jhwanchoi/dotfiles)
- 기술: Vertex AI (Gemini), AWS Bedrock, embeddings/RAG, Claude Code, Gemini CLI, Codex, MCP, CloudWatch, Terraform, n8n

학력

학사 한동대학교, 전자공학 및 컴퓨터공학 — GPA 3.3/4.5

2018년 2월 - 2022년 2월

수강 과목: 자료구조, 알고리즘, 컴퓨터 구조, 딥러닝, 머신러닝