

최지환

📍 서울 ✉ jhwan333@gmail.com ☎ 010-9692-6526 in jihwan-choi 🌐 jhwanchoi

프로필

자율주행 AI를 위한 MLOps 추론·평가 플랫폼을 설계·운영하는 소프트웨어 엔지니어입니다. 공유 Kubernetes GPU 클러스터를 공동 설계(스케줄러·큐 정책 주도)하고, 추론·평가 워크플로우(SVEvalFlow: PRISM, Inferit, MTBF Validation)를 단독 오너십으로 구축·운영합니다.

단일 머신으로 6개월 이상 걸리던 20,000시간 규모 모델 검증을 분산·병렬화로 1.5개월에 완료(173,101 clips, 99.97% 성공률)하고, 비용 분석 기반 On-Premise 전환으로 AWS 대비 4.48억원(55%)을 절감했습니다. 일일 8,000만 건 로그 분석으로 월 1억원 과다 정산을 방지하는 등 기술적 해결을 측정 가능한 비즈니스 가치로 연결해왔습니다. 최근에는 LLM Wiki, Multi-Model Debate, Bedrock 비용 관측 등 AI-native 개발 도구를 직접 만들어 사내에 전파하고 있습니다.

학력

학사 한동대학교, 전자공학 및 컴퓨터공학

2018년 2월 - 2022년 2월

- GPA: 3.3/4.5

- 수강 과목: 자료구조, 알고리즘, 컴퓨터 구조, 딥러닝, 머신러닝

경력

Stradvision, 소프트웨어 엔지니어

서울, 대한민국
2022년 7월 - 현재

MLOps 플랫폼 — 공유 GPU 클러스터 공동 설계 & SVEvalFlow(추론·평가) 오너 (2025년 10월 - 현재)

- RKE2 Kubernetes 기반 공유 GPU 클러스터(60+ 이중 GPU: RTX 3090/4080/4090/5090, RTX 6000)를 타 엔지니어와 공동 설계·구축; 스케줄러·큐 정책 설계 주도, 15+ MLOps 컴포넌트(Ray/KubeRay, MLflow, Airflow, ArgoCD, KServe, Harbor) 통합
- 학습 워크플로우(SVDeepFlow)는 협업, 추론·평가 워크플로우(**SVEvalFlow**)를 단독 오너십으로 설계·구축·운영 — 아래 Inferit, MTBF, PRISM으로 구성
- GitHub Actions + ArgoCD CI/CD 파이프라인 3종, KServe/Knative 기반 Scale-to-Zero 서버리스 추론으로 GPU 유휴 비용 절감
- 기술: RKE2, Ray, KubeRay, KServe, Knative, MLflow, Airflow, ArgoCD, Harbor, lakeFS, GitHub Actions, Helm

Inferit — svnet3 빌드·추론 가속 & 형상관리

- svnet3(사내 자율주행 비전 모델)를 다양한 config로 빌드하는 버전·형상·아티팩트 관리 체계 구축
- 단일 머신 추론을 클러스터 GPU 분산·병렬로 가속 — 20,000시간 데이터 검증을 예상 6개월+에서 1.5개월로 단축
- 고객사 option 파일(카메라 파라미터 등) 형상관리로 엔지니어-PM 간 1-2일 걸리던 탐색·커뮤니케이션 제거
- 메이저 릴리즈 5+ 버전 호환, 고객 이슈 티켓 기반 자동 추론(feature당 주 3회 × OD/LD/TSR/TLR 등 3-4종); Evaluation Driven Development(평가 자동화) 기능 통합
- 기술: Ray, MLflow, lakeFS, Docker, Kubernetes

MTBF Validation — svnet3 대규모 신뢰성 검증

- 릴리즈 전/후 고객 ODD 주행 데이터에 svnet3 추론 후 FP·AEB flag 검출 및 평가 자동화; **173,101 clips**를 **99.97%** 성공률로 처리, 단일 머신 대비 처리량 205% 증가·처리 시간 67.3% 감소
- 비용 분석 기반 Cloud to On-Premise 전환 제안·실행: AWS 8.2억에서 On-Premise 3.7억으로(55% 절감); GPU 하드웨어 벤치마크·사양 제안, HCP Object Storage 활용
- 자동화로 기존엔 규모 한계로 소규모만 가능하던 대규모 검증을 1인 운영으로 전환
- 7종 데이터 검증 파이프라인, 실시간 모니터링 대시보드, Visual Inspection UI(이슈 프레임 전후 영상·통계) + Gemini 보조 검토(최종 판단은 사람)
- 기술: FastAPI, Airflow, Kubernetes, PostgreSQL, HCP Object Storage

PRISM — 고객 Jira 연동 ISP 변환 · Re-simulation 파이프라인 (2025년 11월 -)

- **Phase 1 (배포 · 운영):** Jira Webhook to SQS to Lambda 이벤트 기반 ISP 변환 자동화; 사내 ISP 변환툴 연동; 월 ~150건 처리, 수동 대비 80% 단축
- **Phase 2 (Resim, 개발 중):** 초기 개발 후 테크니컬 리드로 타 조직 개발자 지원 · 관리; SWIT Docker Image 기반 이슈/최신 버전 동시 추론, Airflow DAG 트리거
- **기술:** FastAPI, PostgreSQL, AWS (SQS, Lambda), Terraform, Airflow

데이터 · 라벨링 자동화 (2022 - 2025)

- **WLS:** 일일 8,000만 건 라벨링 로그 수집 · 분석으로 월 약 1억원 과다 정산 방지(정산 감사 확정치); 로그 분석으로 작업 병목을 규명해 UI/UX 개선 및 ALAS 자동 라벨링 모델로 연결, 라벨링 효율 20% 향상 (Django, MongoDB, AWS SQS)
- **ALAS:** 객체 자동 라벨링 마이크로서비스로 수동 라벨링 워크로드 약 35% 감소; ECS to EKS 마이그레이션, CDK 기반 IaC (FastAPI, AWS ECS/EKS, CDK)
- **IGS:** 외부 고객사 데이터 Ingestion 서비스 기획 및 아키텍처 설계(REST API/DB 스키마, Airflow 변환 파이프라인 설계) (Django, Airflow, Kubernetes)
- **SURF Compass:** 데이터 수집 장비 모니터링 서비스 기획 및 설계 (FastAPI, PostgreSQL)
- **RNS:** NestJS + Atlassian API로 Jira 기반 릴리즈 노트 자동 생성, 작성 시간 50% 단축(4시간 에서 2시간) (NestJS, Atlassian API)
- **SLT:** C++/MFC 기반 2D LD 라벨링 툴 개발, 생산성 30% 향상 (C++/MFC)

한국로봇융합연구원, 연구원

- 제스처 인식 기반 실시간 Human-Robot Interaction 시스템 개발
- 자폐 진단 보조 로봇 프로젝트 지원

포항, 대한민국
2022년 1월 - 2022년 7월

기술 스택

언어: Python, C++, TypeScript

Backend: Django, FastAPI, NestJS

Database: PostgreSQL, MongoDB, Redis

Cloud: AWS (EC2, EKS, ECS, SQS, SNS, Lambda, S3, Bedrock)

Infrastructure: Kubernetes (RKE2), Docker, Terraform, CDK, Rancher

ML/MLOps: Ray, KubeRay, MLflow, KServe, Knative, lakeFS

Workflow: Airflow, Celery

CI/CD: ArgoCD, GitHub Actions, Harbor, Helm

Monitoring: Grafana, Prometheus, Loki, DataDog

AI/LLM: Claude Code, Gemini CLI, Codex, MCP, AWS Bedrock, n8n

Tools: Git, Jira, Confluence, Atlassian API

AI-Native 개발 & 사내 전파

- **LLM Wiki:** Git + Markdown 기반 MLOps 운영 지식 관리 시스템 설계(자연어 문서 작성 · 검색 · 질의응답 · 품질 린트 · 동기화); 개인에 흩어진 운영 지식을 팀 자산으로 축적하고 외부 의존성을 제거해 사용 마찰 해소
- **Multi-Model Debate Hooks:** Claude · GPT · Gemini가 초안 to 비판 to 제3자 리뷰 to 종합으로 교차검증하는 워크플로우 설계로 설계 리뷰 · 중요 문서의 신뢰도 향상 (github.com/jhwanchoi/dotfiles, LinkedIn 공개)
- **Bedrock** 사용량 관측: 사내 LLM 사용량 · 비용 가시화 모니터링 인프라(CloudWatch 대시보드 + Slack 알림) 구축; 진단 · 스토리지 등 클러스터 운영 Claude 플러그인 제공
- **MTBF Visual Inspection AI** 보조: 대규모 검증 결과 검토에 Gemini를 보조 도입(최종 판단은 사람)하여 반복 확인 부담 완화; n8n 업무 자동화 프로토타입(PR 요약 · 리뷰, 기술 뉴스봇, 클러스터 모니터링, 채용 보조)
- AI-driven development 사내 미팅 호스트; 최신 AI 개발 도구(Claude Code, Gemini CLI, Codex; Plugin/MCP/Skill) 트랜드 전파
- **기술:** Claude Code, Gemini CLI, Codex, MCP, AWS Bedrock, CloudWatch, n8n