

\$ cat profile.md

최지환

MLOps · 소프트웨어 엔지니어 · SVEvalFlow Owner

서울, 대한민국 · jhwan333@gmail.com · 010-9692-6526 · linkedin.com/in/jihwan-choi · github.com/jhwanchoi
· jhwanchoi.github.io

4.48억

AWS 대비 절감

6개월→1.5개월

검증 시간

99.97%

성공률

8천만/일

로그 이벤트

01 프로필

자율주행 AI를 위한 MLOps 추론·평가 플랫폼을 설계·운영하는 소프트웨어 엔지니어입니다. 공유 Kubernetes GPU 클러스터를 공동 설계(스케줄러·큐 정책 주도)하고, 추론·평가 워크플로우(SVEvalFlow: PRISM, Inferit, MTBF Validation)를 단독 오너십으로 구축·운영합니다.

단일 머신으로 6개월 이상 걸리던 20,000시간 규모 모델 검증을 분산·병렬화로 1.5개월에 완료(173,101 clips, 99.97% 성공률)하고, 비용 분석 기반 On-Premise 전환으로 AWS 대비 4.48억원(55%)을 절감했습니다. 일일 8,000만 건 로그 분석으로 월 1억원 과다 정산을 방지하는 등 기술적 해결을 측정 가능한 비즈니스 가치로 연결해왔습니다. 최근에는 프로덕션 Generative AI — Vertex AI 기반 Gemini 멀티모달 추론(실고객 릴리즈 운영), 토큰·request당 비용 단위의 LLM 비용/사용량 관측, RAG, agentic 툴링 — 을 직접 만들고 AI-native 개발을 사내에 전파하고 있습니다.

02 학력

한동대학교

2018.02 - 2022.02

학사 — 전자공학 및 컴퓨터공학

▶ GPA: 3.3 / 4.5

▶ 수강 과목: 자료구조, 알고리즘, 컴퓨터 구조, 디리닝, 머신러닝

03 경력

Stradvision

소프트웨어 엔지니어
서울 · 2022.07 - 현재

MLOps 플랫폼 — 공유 GPU 클러스터 공동 설계 & SVEvalFlow(추론·평가) 오너 (2025.10 - 현재)

- ▶ RKE2 Kubernetes 기반 공유 GPU 클러스터(60+ 이중 GPU: RTX 3090/4080/4090/5090, RTX 6000)를 타 엔지니어와 공동 설계·구축; 스케줄러·큐 정책 설계 주도, 15+ MLOps 컴포넌트(Ray/KubeRay, MLflow, Airflow, ArgoCD, KServe, Harbor) 통합.
- ▶ 학습 워크플로우(SVDeepFlow)는 협업, 추론·평가 워크플로우(SVEvalFlow)를 단독 오너십으로 설계·구축·운영 — 아래 Inferit, MTBF, PRISM으로 구성.
- ▶ GitHub Actions + ArgoCD CI/CD 파이프라인 3종, KServe/Knative 기반 Scale-to-Zero 서버리스 추론으로 GPU 유휴 비용 절감.

기술: RKE2, Ray, KubeRay, KServe, Knative, MLflow, Airflow, ArgoCD, Harbor, lakeFS, GitHub Actions, Helm

Inferit — svnet3 빌드·추론 가속 & 형상관리

- ▶ svnet3(사내 자율주행 비전 모델)를 다양한 config로 빌드하는 버전·형상·아티팩트 관리 체계 구축.
- ▶ 단일 머신 추론을 클러스터 GPU 분산·병렬로 가속 — 20,000시간 데이터 검증을 예상 6개월+에서 1.5개월로 단축.
- ▶ 고객사 option 파일(카메라 파라미터 등) 형상관리로 엔지니어-PM 간 1-2일 걸리던 탐색·커뮤니케이션 제거.
- ▶ 메이저 릴리즈 5+ 버전 호환, 고객 이슈 티켓 기반 자동 추론; Evaluation Driven Development(평가 자동화) 통합.

기술: Ray, MLflow, lakeFS, Docker, Kubernetes

MTBF Validation — svnet3 대규모 신뢰성 검증

- ▶ 릴리즈 전/후 고객 ODD 주행 데이터에 svnet3 추론 후 FP·AEB flag 검출 및 평가 자동화; **173,101 clips를 99.97% 성공률**로 처리, 단일 머신 대비 처리량 205% 증가·처리 시간 67.3% 감소.
- ▶ 비용 분석 기반 Cloud → On-Premise 전환 제안·실행: AWS 8.2억 → On-Premise 3.7억(55% 절감); GPU 하드웨어 벤치마크·사양 제안, HCP Object Storage 활용.
- ▶ 자동화로 기존엔 소규모만 가능하던 대규모 검증을 1인 운영으로 전환; Visual Inspection UI + **Vertex AI 기반 Gemini 2.5 Flash** 자동 FP 검출 보조(멀티모달·structured output; 최종 판단은 사람).

기술: FastAPI, Airflow, Kubernetes, PostgreSQL, HCP Object Storage, Vertex AI (Gemini)

PRISM — 고객 Jira 연동 ISP 변환·Re-simulation 파이프라인 (2025.11 -)

- ▶ **Phase 1 (배포·운영):** Jira Webhook → SQS → Lambda 이벤트 기반 ISP 변환 자동화; 사내 ISP 변환툴 연동; 월 ~150건 처리, 수동 대비 80% 단축.
- ▶ **Phase 2 (Resim, 개발 중):** 초기 개발 후 **테크니컬 리드**로 타 조직 개발자 지원·관리; SWIT Docker Image 기반 이슈/최신 버전 동시 추론, Airflow DAG 트리거.

기술: FastAPI, PostgreSQL, AWS (SQS, Lambda), Terraform, Airflow

데이터·라벨링 자동화 (2022 - 2025)

- ▶ **WLS:** 일일 8,000만 건 라벨링 로그 수집·분석으로 월 약 1억원 과다 정산 방지(정산 감사 확정치); 작업 병목을 규명해 UI/UX 개선 및 ALAS 모델로 연결, 라벨링 효율 20% 향상. (Django, MongoDB, AWS SQS)
- ▶ **ALAS:** 객체 자동 라벨링 마이크로서비스로 수동 라벨링 워크로드 약 35% 감소; ECS → EKS 마이그레이션, CDK 기반 IaC. (FastAPI, AWS ECS/EKS, CDK)
- ▶ **IGS:** 외부 고객사 데이터 Ingestion 서비스 기획 및 아키텍처 설계(설계 전담). (Django, Airflow, Kubernetes)
- ▶ **SURF Compass:** 데이터 수집 장비 모니터링 서비스 기획 및 설계(설계 전담). (FastAPI, PostgreSQL)
- ▶ **RNS:** Jira 기반 릴리즈 노트 자동 생성, 작성 시간 50% 단축(4시간 → 2시간). (NestJS, Atlassian API)
- ▶ **SLT:** C++/MFC 기반 2D LD 라벨링 툴 개발, 생산성 30% 향상. (C++/MFC)

한국로봇융합연구원

연구원
포항 · 2022.01 - 2022.07

- ▶ 제스처 인식 기반 실시간 Human-Robot Interaction 시스템 개발.
- ▶ 자폐 진단 보조 로봇 프로젝트 지원.

04 기술 스택

언어	Python · C++ · TypeScript
Backend	Django · FastAPI · NestJS
Database	PostgreSQL · MongoDB · Redis
Cloud	GCP (Vertex AI) · AWS (EC2, EKS, ECS, SQS, SNS, Lambda, S3, Bedrock)
Infrastructure	Kubernetes (RKE2) · Docker · Terraform · CDK · Rancher
ML / MLOps	Ray · KubeRay · MLflow · KServe · Knative · lakeFS
Workflow / CI-CD	Airflow · Celery · ArgoCD · GitHub Actions · Harbor · Helm
Monitoring	Grafana · Prometheus · Loki · DataDog
Generative AI / LLM	Vertex AI (Gemini) · AWS Bedrock · 멀티모달 · structured output · RAG / embeddings · 프롬프트 엔지니어링 · LLM 비용·관측 · agentic / tool-use · 멀티모델 오케스트레이션 · Claude Code / MCP / Skills
Tools	Git · Jira · Confluence · Atlassian API

05 Generative AI Engineering & 사내 전파

- ▶ **Gemini · Vertex AI (프로덕션·멀티모달):** 자율주행 비전 모델 추론 결과 자동 FP 검출용 Vertex AI 기반 Gemini 2.5 Flash 서비스 (이미지 + 구조화 메타데이터); JSON 스키마 structured output, request당 토큰 추적, 배치 비동기 + 중복제거(~40% 호출 감소), 휴먼인터루프; 실고객 릴리즈 평가 운영(MTBF).
- ▶ **LLM 비용·사용량 관측 (AWS Bedrock):** 토큰 단위 및 모델·팀별 request당 비용 귀속을 CloudWatch + Slack, Terraform IaC로 구현; 청구 대비 90%+ 정확도, 조직 차원 비용 최적화 의사결정 도구로 활용.
- ▶ **RAG 지식 시스템 (LLM Wiki):** 키워드 + 임베딩 하이브리드 검색(text-embedding-3-small, 벡터 인덱스, 코사인 top-k) → 출처·신선도를 갖춘 근거 답변; CI 임베딩 인덱스 재생성 (Git + Markdown).
- ▶ **Agentic LLM 툴링:** 자연어 의도 → 클러스터 진단/스토리지 도구 호출(Claude Code Skills), 멀티스텝 오케스트레이션 + 가드레일 (dry-run, 롤백, 확인 게이트); 멀티모델 자기비판 워크플로우(Claude/GPT/Gemini) (github.com/jhwancoi/dotfiles).
- ▶ AI-driven development 사내 미팅 호스트; 최신 AI 개발 도구(Claude Code, Gemini CLI, Codex; Plugin/MCP/Skill) 트렌드 전파; n8n 업무 자동화 프로토타입.

기술: Vertex AI (Gemini), AWS Bedrock, embeddings/RAG, Claude Code, Gemini CLI, Codex, MCP, CloudWatch, Terraform, n8n