최지환

서울 jhwan333@gmail.com 010-9692-6526 jihwan-choi jhwanchoi jhwanchoi.github.io

프로필

프로덕션 Generative AI와 자율주행 AI를 위한 **MLOps 추론·평가 플랫폼**을 만들고 운영하는 소프트웨어 엔지니어입니다. **비용 인지형 멀티모달 VLM 평가 시스템**(rule tier → local VLM → AWS Bedrock escalation), **LLM 비용·사용량 관측**, **RAG**, **agentic 툴링**을 직접 구축합니다. 공유 Kubernetes GPU 클러스터를 공동 설계하며 **스케줄러·큐 정책을 주도**하고, **SVEvalFlow 추론·평가 워크플로우의 설계·구축·운영을 직접 책임집니다**. MTBF에서 **430,851개 클립·15,233시간의 주행 데이터**를 **파이프라인 처리 성공률 99.87%**로 검증(2026.06 누적)하고, GPU 벤치마크·비용 분석을 바탕으로 온프레미스 전환을 수행해 **AWS 대비 비용 55%를 절감**했습니다. 일일 8,000만 건 로그 분석 플랫폼으로 **월 약 1억원 과다 정산을 방지**했습니다.

경력

Stradvision, 소프트웨어 엔지니어

서울, 대한민국
2022년 7월 - 현재

공유 GPU 클러스터 및 추론·평가 [Link]

SVEvalFlow 설계·구축·운영 (2025년 10월 - 현재)

기술: RKE2, Ray, KubeRay, KServe, Knative, MLflow, Airflow, ArgoCD, Harbor, lakeFS, GitHub Actions, Helm

- RKE2 Kubernetes 기반 공유 GPU 클러스터(60+ 이종 GPU: RTX 3090/4080/4090/5090, RTX 6000)를 타 엔지니어와 공동 설계·구축하며 **스케줄러·큐 정책 설계를 주도**. 긴급 평가가 실행 중인 bulk job에서 부족 GPU만 선점하고 완료 후 자동 반환하는 애플리케이션 레벨 스케줄러를 프로덕션 배포하고, 15+ MLOps 컴포넌트(Ray/KubeRay, MLflow, Airflow, ArgoCD, KServe, Harbor 등)를 통합
- 학습 워크플로우(SVDeepFlow)는 협업, **추론·평가 워크플로우(SVEvalFlow)를 단독으로 책임지고** 설계·구축·운영 — 아래 Inferit·MTBF·PRISM으로 구성
- GitHub Actions + ArgoCD CI/CD 파이프라인 3종, KServe/Knative 기반 Scale-to-Zero 서버리스 추론으로 GPU 유휴 비용 절감
- AI-native 개발 도구(Claude Code, Gemini CLI, Codex; MCP/Plugin/Skill)의 사내 도입을 주도 — 실무 엔지니어링 세션 진행

모델 실행 이미지 빌드·관리 (Inferit) [Link]

자율주행 인지 모델 svnet3의 실행 환경·아티팩트 관리

기술: FastAPI, Airflow, Kubernetes, lakeFS, Docker, PostgreSQL, HCP Object Storage

- svnet3(사내 자율주행 비전 모델)의 버전·형상·아티팩트 관리 체계를 구축하고, branch, config, commit 및 CUDA 환경(cu118, cu128) 기준 worker image 조회·빌드 API를 MTBF에 연동해 최신 base·버전·digest·custom override를 일관되게 추적
- 고객사 option 파일(카메라 파라미터 등)을 형상관리해 **티켓마다 1~2일 걸리던 엔지니어·PM 간 탐색·핸드오프를 제거**
- **메이저 릴리즈 5+ 버전** 및 고객 이슈 티켓 기반 자동 추론 지원, 평가 자동화 연동

경력 (계속)

Stradvision, 소프트웨어 엔지니어 2022년 7월 - 현재

자율주행 모델 GPU 추론 · 검증 (MTBF) [Link]

초기 시스템부터 단계적 고도화 (2025년 3월 - 현재)

기술: FastAPI, Airflow, Kubernetes (RKE2, NKS), Docker, PostgreSQL, HCP/NCP Object Storage, AWS Bedrock, Prometheus, Grafana, Loki, DCGM, Keycloak/Okta

- 초기 시스템부터 단계적으로 고도화하며 svnet3 인지 모델의 GPU 추론, 데이터 검증, 평가 결과 · 이력 및 Visual Inspection UI 연동 구현 (FastAPI, Airflow, Kubernetes)
- **430,851개 클립 · 15,233시간의 주행 데이터**를 **파이프라인 처리 성공률 99.87%**로 처리(2026.06 누적). 단일 머신 대비 **파이프라인 처리량 205% 증가 · 처리 시간 67.3% 감소**
- 7종 데이터 검증 파이프라인 · 실시간 대시보드 구축 · 운영 및 릴리즈 전 · 후 오탐(false positive) · 자동 긴급제동(AEB) 플래그 검토 자동화로 **대규모 검증 1인 운영** 실현. rule tier → local VLM → AWS Bedrock 기반 평가 보조 결과는 사람의 검수 후 최종 KPI에 반영
- GPU 하드웨어 벤치마크 · 사양 제안 · 비용 분석을 바탕으로 클라우드에서 온프레미스로의 전환을 제안 · 실행하여 **AWS 대비 비용 55% 절감**
- 온프레미스 MTBF를 **NCP NKS/L40S · Object Storage · NCR로 이관하고 2026.09 완전 전환 완료**. PostgreSQL 이력 및 스토리지 이관, 객체 목록 · 배치 매니페스트 기반 이관 정합성 확인
- **Prometheus/Grafana/Loki/DCGM 모니터링 구축 및 GPU 지표 검증**, 개발 · 운영 환경 **Keycloak/Okta SSO 연동 직접 구현**
- **L40S GPU 56장**으로 **1,068시간 주행 데이터의 57,745개 명령을 23시간 57분에 실행**, **57,710건 완료(99.94%)**. 해당 실행에서 **VRAM 사고 · 파드 축출 0건** 관측
- 해당 NCP 실행에서 **GPU 노드 1→14대를 13분 내 자동 확장**, 완료 후 1대로 축소 검증

이미지 처리 · 재시뮬레이션 연동 (PRISM) [Link]

Jira 연동 ISP 변환 및 버전별 추론 (2025년 11월 - 현재)

기술: FastAPI, Airflow, PostgreSQL, AWS (SQS, Lambda), Terraform

- **Phase 1 (전개 준비)**: Jira Webhook → SQS → Lambda 기반 이미지 신호 처리(ISP) 변환 연동 및 Terraform 구성 구현. 연동 테스트 완료, Inferit 전개 후 완전 전개 예정
- **Phase 2 (재시뮬레이션, 개발 중)**: 초기 구현 개발 및 타 조직 개발자의 구현 지원. 재시뮬레이션 Docker 이미지 · Airflow 기반 버전별 추론 연동 개발

경력 (계속)

Stradvision, 소프트웨어 엔지니어 2022년 7월 - 현재

데이터 · 라벨링 자동화 (2022 - 2025)

- **WLS:** 일일 8,000만 건 라벨링 로그 수집 · 분석으로 월 약 1억원 과다 정산 방지(정산 감사 확정치). 로그 분석으로 작업 병목을 규명해 UI/UX 개선 및 ALAS 자동 라벨링 모델로 연결하고, 라벨링 효율을 20% 향상 (Django, MongoDB, AWS SQS)
- **ALAS:** 객체 자동 라벨링 마이크로서비스로 수동 라벨링 워크로드 약 35% 감소. ECS to EKS 마이그레이션, CDK 기반 IaC (FastAPI, AWS SQS, AWS SNS, AWS ECS/EKS, CDK)
- **IGS:** 외부 고객사 데이터 Ingestion 서비스 기획 및 아키텍처 설계(REST API/DB 스키마, Airflow 변환 파이프라인 설계) (Django, Airflow, Kubernetes)
- **SURF Compass:** 데이터 수집 장비 모니터링 서비스 기획 및 설계 (FastAPI, PostgreSQL)
- **RNS:** NestJS + Atlassian API로 Jira 기반 릴리즈 노트 자동 생성, 작성 시간 50% 단축(4시간 에서 2시간) (NestJS, Atlassian API)
- **SLT:** C++/MFC 기반 2D LD 라벨링 툴 개발, 생산성 30% 향상 (C++/MFC)

한국로봇융합연구원, 연구원 포항, 대한민국

2022년 1월 - 2022년 7월

- 제스처 인식 기반 실시간 Human-Robot Interaction 시스템 개발
- 자폐 진단 보조 로봇 프로젝트 지원

기술 스택

언어: Python, C++, TypeScript
Backend: Django, FastAPI, NestJS
Database: PostgreSQL, MongoDB, Redis
Cloud: AWS (EC2, EKS, ECS, SQS, SNS, Lambda, S3, Bedrock), NCP (NKS, Object Storage, NCR), GCP (Vertex AI)
Infrastructure: Kubernetes (RKE2, NKS), Docker, Terraform, CDK, Rancher
ML/MLOps: Ray, KubeRay, MLflow, KServe, Knative, lakeFS
Workflow: Airflow, Celery
CI/CD: ArgoCD, GitHub Actions, Harbor, Helm
Monitoring: Grafana, Prometheus, Loki, CloudWatch, DCGM, DataDog
Authentication: Keycloak, Okta (SSO 연동)
Generative AI / LLM: Local VLM, AWS Bedrock (Claude), Vertex AI (Gemini), 멀티모달, structured output, RAG / embeddings, 프롬프트 엔지니어링, LLM 비용 · 관측, agentic / tool-use, Claude Code / MCP / Skills
Tools: Git, Jira, Confluence, Atlassian API

Generative AI Engineering

- **계층형 멀티모달 VLM 평가 (프로덕션):** 초기 Gemini/Vertex AI 서비스를 1,110건 golden set으로 재설계. rule tier가 79.5%를 처리하고 local VLM을 기본 사용하며, 모호한 issue-axis ~16%만 AWS Bedrock Claude Opus로 escalation. self-consistency · JSON schema · 반출 승인 · human-review state machine을 적용하고 미검수 결과는 KPI에서 제외 (MTBF)
- **LLM 비용 · 사용량 관측 (AWS Bedrock):** 토큰 단위 및 모델 · 팀별 request당 비용 귀속을 CloudWatch + Slack으로 노출하고 Terraform IaC로 구현. 청구 대비 90%+ 정확도, 조직 차원 비용 최적화 의사결정 도구로 활용
- **RAG 지식 시스템 (LLM Wiki):** 키워드 + 임베딩 하이브리드 검색(text-embedding-3-small, 벡터 인덱스, 코사인 top-k) → 출처 · 최신성 · 불확실성 표시를 갖춘 근거 답변. CI 임베딩 인덱스 재생성 (Git + Markdown)
- **Agentic LLM 툴링:** 자연어 의도 → 클러스터 진단/스토리지 도구 호출(Claude Code Skills), 멀티스텝 오케스트레이션 + 가드레일(dry-run, 롤백, 확인 게이트) 적용. 멀티모델 자기비판 워크플로우(Claude/GPT/Gemini) 운영 (jhwanchoi/dotfiles)
- **기술:** Local VLM, AWS Bedrock (Claude), Vertex AI (Gemini), embeddings/RAG, Claude Code, Gemini CLI, Codex, MCP, CloudWatch, Terraform, n8n

학력

학사 **한동대학교**, 전자공학 및 컴퓨터공학 — GPA 3.3/4.5 2018년 2월 - 2022년 2월

수강 과목: 자료구조, 알고리즘, 컴퓨터 구조, 딥러닝, 머신러닝